

## Outlier detection - Détection de fraudes

H. Andres & M. Bouazza & M. Casanave & M. Karpe

École des Ponts ParisTech

25 mai 2018

# Sommaire

Introduction

Algorithmes de détection de données aberrantes

Modélisation économique du coût de la fraude


Expérimentations et résultats

Conclusion

# Introduction

## Comment détecter les données aberrantes ?

Une étude comparative des différents algorithmes d'apprentissage  
non supervisé



# Sommaire

Introduction

Algorithmes de détection de données aberrantes

Modélisation économique du coût de la fraude

Expérimentations et résultats

Conclusion

# Autoencoder

## Principe :

- Codeur :  $\psi : x \in \mathbb{R}^d \mapsto z \in \mathbb{R}^{d'} \ (d' < d)$
- Decodeur :  $\phi : z \in \mathbb{R}^{d'} \mapsto \tilde{x} \in \mathbb{R}^d$
- $\psi, \phi = \underset{\psi, \phi}{\operatorname{argmin}} \|X - \phi \circ \psi(X)\|_{\mathbb{R}^d}^2$  ( $X$  étant le jeu de données)




Figure – Illustration du principe de *Autoencoder*.

# Autoencoder

- **Idée** : "outlier" moins bien représenté
- **Conséquence** : erreur d'approximation  $\|x - \phi \circ \psi(x)\|_{\mathbb{R}^d}^2$  plus grande
- **Détection** : données ayant les plus grandes erreurs

## Local Outlier Factor

Idée : Comparaison de la densité avec les  $k$  voisins




Figure – Illustration de la méthode *Local Outlier Factor*.

# Local Outlier Factor

## En pratique :

- "Distance d'atteinte"  $d_k(x, y)$  : maximum de la vraie distance  $d(x, y)$  et de la distance entre  $y$  et son  $k^e$  voisin
- "Densité locale" de  $x$  : inverse de la moyenne des distances d'atteinte de  $x$  depuis ses  $k$  voisins



## Robust Estimator of Covariance

**Hypothèses** :  $X_i \sim N_p(\mu_i, \sigma_i)$  données générées à partir d'une densité elliptique

**Robustesse** : Modèle imposé par la **majorité** des données, donc moins influencé par les outliers

**Distance de Mahalanobis** :  $D_M(x) = \sqrt{(x - \mu)^T \Sigma^{-1}(x - \mu)}$

$x$  outlier si n'appartient pas à l'**ellipsoïde de tolérance** :

$$\left\{ x \mid D_M(x) \leq \sqrt{\chi_{p,0.975}^2} \right\}$$

## Robust Estimator of Covariance





Figure – Illustration d'une ellipsoïde de tolérance.

# One-class SVM

## Principe :

- Fonction de décision : hyperplan
- Applique le noyau et sépare les données
- Outliers relâchés par une variable  $\xi$
- $\nu$  est choisi par l'utilisateur



## Programme de minimisation :

$$\begin{aligned} \min_{w, \xi_i, \rho} \quad & \frac{1}{2} \|w\|^2 + \frac{1}{\nu n} \sum_{i=1}^n \xi_i - \rho \\ \text{s.t.} \quad & (w \cdot \phi(x_i)) \geq \rho - \xi_i, \quad \xi_i \geq 0, \quad \forall i = 1, \dots, n \end{aligned}$$

Fonction à noyau :  $K(x, x_i) = \phi(x)^T \phi(x_i)$

Fonction de décision :  $f(x) = \text{sgn}((w \cdot \phi(x_i)) - \rho)$

# One-class SVM




Figure – Illustration de la méthode *One-class SVM*.

# Isolation Forest

**Hypothèses principales** : *outliers* = points en faible nombre et différents des autres

**Conséquence** : *outliers* faciles à isoler





Figure – Illustration de la méthode *Isolation Forest*.

# Isolation Forest

iTree



# Sommaire

Introduction

Algorithmes de détection de données aberrantes

Modélisation économique du coût de la fraude

Expérimentations et résultats

Conclusion

## Coûts et profits pour la banque

		P R E D I C T E D	
A C T U A L	P	"P"	"N"
		TRUE POSITIVE	FALSE NEGATIVE
		Outlier detected as outlier	Outlier detected as inlier
		Profit: €160	Cost: €160
	N	FALSE POSITIVE	TRUE NEGATIVE
		Inlier detected as outlier	Inlier detected as inlier
		Cost: €1	Profit: €0

Figure – Illustration des différents coûts intervenant dans la modélisation.



## Stratégie de maximisation

$$\pi = 160(TPR - FNR) - FPR \quad \text{avec}$$

$$TPR = \frac{\# \text{ Vrais positifs}}{\# \text{ Positifs}}$$

$$FNR = \frac{\# \text{ Faux négatifs}}{\# \text{ Positifs}}$$

$$FPR = \frac{\# \text{ Faux positifs}}{\# \text{ Négatifs}}$$

# Sommaire

Introduction

Algorithmes de détection de données aberrantes

Modélisation économique du coût de la fraude

**Expérimentations et résultats**

Conclusion

## Jeux de données

	Données	Dimensions	Outliers
Synthetic	1000	100	13,6 %
<b>Creditcard</b>	<b>284807</b>	<b>29</b>	<b>0,17 %</b>
KDD10	494021	38	1,77 %
SA10	100655	38	3,36 %
SF10	73237	3	4,50 %
HTTP10	58725	3	3,76 %
SMTP10	9571	3	0,03 %

Figure – Description des jeux de données utilisés dans le cadre du projet.

# Optimisation des hyperparamètres





Figure – Illustration des méthodes de *Grid Search* (à gauche) et de *validation croisée* (à droite).

# Description et analyse des résultats

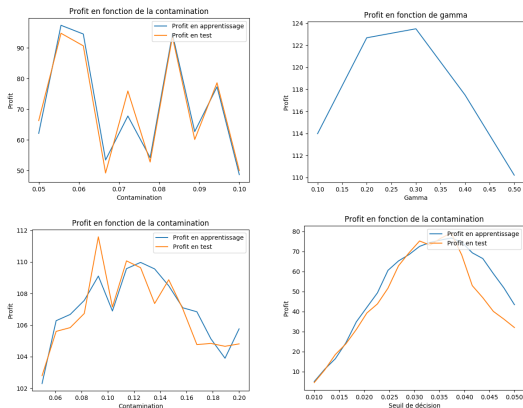


Figure – Evolution de la fonction de profit en fonction de la valeur de l'hyperparamètre caractéristique de l'algorithme.

## Combinaison des algorithmes





Figure – Evolution de la fonction de profit en fonction du seuil de décision pour la combinaison des algorithmes par *rank averaging* (à gauche) et par *bagging* (à droite).

# Sommaire

Introduction

Algorithmes de détection de données aberrantes

Modélisation économique du coût de la fraude

Expérimentations et résultats

Conclusion

# Synthèse et perspectives

## Constats majeurs :

- One-class SVM semble être le plus efficace
- Combinaison des algorithmes peu efficace
- Importance de la fonction de coût / profit

## Limites du projet :

- Taille des bases de données
- Temps d'exécution des algorithmes



# Principales références I



Observatoire de la sécurité des moyens de paiement - Banque de France

Rapport annuel de l'Observatoire de la sécurité des moyens de paiement

[https://www.banque-france.fr/sites/default/files/medias/documents/osmp2016\\_web.pdf](https://www.banque-france.fr/sites/default/files/medias/documents/osmp2016_web.pdf)  
2016



Journal of Machine Learning Research

Scikit-learn : Machine Learning in Python

<http://scikit-learn.org/stable/>  
2011